UNIVERSIDAD DE GUADALAJARA
CENTRO UNIVERSITARIO DE GUADALAJARA
LIC. EN INTELIGENCIA ARTIFICIAL Y CIENCIA DE DATOS

PROYECTO FINAL

Pipeline Completo de Ingeniería de Datos

Ingesta · Extracción · Transformación · Serving · Aplicación

ALUMNO: ROBERTO ALEJANDRO CHAGRA MARTINEZ
CODIGO: 208447128
MATERIA: FUNDAMENTOS DE INGENIERIA DE DATOS
DOCENTE: GUSTAVO CANDELARIO GUZMAN
FECHA: 12 DE MAYO DE 2026

Descripción del Dataset

- **Referencia:** Kaggle - *Global Movies Dataset (1950-2026)*. https://www.kaggle.com/datasets/suhanigupta04/global-movies-dataset-19502026
- **Volumen de Datos:** 100,000 filas.
- **Columnas Disponibles:** 27 columnas (incluyendo budget_million, revenue_million, popularity_score, runtime_min, release_year, etc.).
- **Variable Objetivo Elegida:** blockbuster_flag (Clasificación binaria).
- **Criterio de División:** Partición cronológica equitativa. El dataset se ordenó por año de lanzamiento y se fragmentó en 5 bloques de 20,000 filas cada uno para simular una ingesta histórica.
- **Tabla de subconjuntos:**

Fuente	***Filas***	***Rango de Fechas (Años)***	***Descripción del Periodo***
raw_fuente_1	20,000	1950 - 1965	Cine Clásico / Época de Oro
raw_fuente_2	20,000	1965 - 1980	Transición y Nuevo Hollywood
raw_fuente_3	20,000	1980 - 1996	Surgimiento del Blockbuster Moderno
raw_fuente_4	20,000	1996 - 2011	Era Digital y Globalización
raw_fuente_5	20,000	2011 - 2026	Cine Contemporáneo y Proyecciones

Diseño del Star Schema

Para la capa **Serving**, se consolidó la información en una estructura de Esquema Estrella para optimizar la velocidad de lectura y el entrenamiento del modelo.

Tabla	***Tipo***	***Clave Primaria (PK)***	***Claves Foráneas (FK)***	***Descripción de Métricas***
serving_fact_movies	**Fact**	**metadata_uuid**	**N/A (Denormalizada)**	**budget, revenue, popularity, top_100_prob.**

Justificación de elección: Se eligió **Star Schema** sobre Snowflake debido a que, con 100,000 registros, la prioridad es minimizar los *joins* complejos. Al tener una tabla de hechos denormalizada,

el acceso a los datos para el entrenamiento de Machine Learning es directo y eficiente, reduciendo la latencia de consulta.

Documentación de Transformaciones

Se aplicó un estándar de limpieza riguroso en la capa **Silver** para las 5 fuentes.

Fuente	***Transformaciones Aplicadas***	***Estrategia de Nulos***	***Columnas con Atípicos***	***Columnas Normalizadas***
Fuentes 1-5	strip() en cabeceras, minúsculas en textos, eliminación de ruido de IDs.	Imputación por Mediana en numéricos; "Unknown" en categóricos.	revenue_million, budget_million.	Géneros, Idiomas, Países.

Descripción del Modelo

- **Tipo de modelo:** Random Forest Classifier.
- **Justificación:** Excelente manejo de variables categóricas y capacidad para capturar relaciones no lineales entre el presupuesto y el éxito comercial en grandes volúmenes de datos (100k).
- **Hiperparámetros:** n_estimators=100, random_state=42, max_depth=None.
- **Variable objetivo:** blockbuster_flag.
- **Features utilizadas:** budget_million, marketing_budget_million, popularity_score, runtime_min, genre (codificado), lead_actor (codificado).

Resultados del Modelo

Resultados obtenidos tras procesar el 100% de la capa Gold:

Métrica	***Valor***
Accuracy	***99.79%***
Precision	***99.55%***
Recall	***99.48%***
F1-Score	***99.51%***

Matriz de confusión

	Predicho: No Blockbuster	***Predicho: Blockbuster***
Real: No Blockbuster	***15,518***	***20***
Real: Blockbuster	***23***	***4,439***

Análisis de resultados: El modelo de clasificación **Random Forest** presenta un desempeño excepcional y altamente robusto tras procesar el 100% de la capa Gold. Con una **Exactitud (Accuracy) del 99.79%** y un **F1-Score del 99.51%**, el algoritmo demuestra una capacidad casi perfecta para balancear la precisión y la exhaustividad en la identificación de películas taquilleras.

Al desglosar el comportamiento del modelo mediante la **Matriz de Confusión** y las métricas específicas, se pueden extraer las siguientes conclusiones clave:

- **Alta Precisión (99.55%):** De todas las películas que el modelo clasificó como *Blockbuster*, el 99.55% realmente lo eran. La matriz de confusión respalda esto al registrar únicamente **20 falsos positivos** (películas catalogadas erróneamente como éxitos comerciales). Esta precisión milimétrica se debe principalmente a la correlación directa y lineal entre el Retorno de Inversión (ROI) y la variable objetivo definida en el set de datos.
- **Sensibilidad / Recall Elevado (99.48%):** El modelo fue capaz de detectar el 99.48% de todos los *Blockbusters* reales presentes en el dataset , dejando escapar únicamente **23 falsos negativos** (películas exitosas que se clasificaron como no taquilleras).
- **Impacto del Volumen Histórico:** La disponibilidad de un volumen robusto de **100,000 filas** segmentadas cronológicamente permitió al algoritmo de ensamble aprender patrones de éxito extremadamente específicos y dinámicos para cada una de las décadas evaluadas (desde el cine clásico hasta las proyecciones contemporáneas) , evitando problemas de sobreajuste gracias a la naturaleza del Random Forest.

En conclusión, el bajísimo volumen de errores funcionales (solo 43 clasificaciones incorrectas de un universo de 20,000 evaluadas en la matriz) confirma que el star schema de la capa Serving alimenta al modelo de manera óptima y directa, garantizando una latencia mínima y una alta fidelidad predictiva.

Tabla de Tiempos de Consulta (Capa SERVING)

Pruebas de rendimiento realizadas sobre los 100,000 registros unificados:

Tipo de Consulta	***Tiempo Promedio***
Lectura total de la tabla (100k filas)	~145 ms
Filtrado por década (COUNT)	~22 ms
Carga de features para entrenamiento	~85 ms
Búsqueda por PK (UUID)	~2.1 ms